Экспериментальное исследование ландшафтной меры сложности нейросетевой модели при варьировании dropout

Глезин Родион Романович

2026

Аннотация

В работе рассматривается экспериментальная проверка ландшафтной меры сложности параметрической модели глубокого обучения. В качестве теоретической основы используется подход, в котором сложность модели определяется через изменение локальной кривизны функции потерь при варьировании элементов выборки. Локальная кривизна описывается матрицами Гессе функции потерь по параметрам модели. Целью работы является исследование зависимости эмпирической оценки ландшафтной меры от вероятности dropout. Рассматриваются два вычислительных подхода: приближенный метод на основе произведений Гессиана на вектор для последнего линейного слоя и прямое вычисление полной матрицы Гессе для малой сверточной модели. Обсуждаются различия между этими методами, причины различий в экспериментальных графиках и направления дальнейшей работы.

1 Введение

Одной из центральных задач теории глубокого обучения является построение количественных характеристик сложности модели, которые были бы связаны не только с числом параметров, но и с геометрией задачи оптимизации. Классические меры сложности, такие как VC-размерность, PAC-оценки и радемахеровская сложность, часто оказываются чрезмерно грубыми для современных нейросетевых моделей, поскольку они ориентированы на оценки худшего случая и слабо учитывают конкретную структуру данных, регуляризацию и свойства найденного минимума.

В диссертационной работе А. В. Грабового [1] предлагается подход, в котором сложность параметрической модели связывается с локальным поведением функции потерь. Основной объект анализа — матрица Гессе функции потерь по параметрам модели. Такая матрица описывает локальную кривизну оптимизационного ландшафта и тем самым позволяет перейти от формального подсчета числа параметров к анализу того, насколько устойчиво ведет себя модель в окрестности найденного решения.

В настоящей работе была изучена и экспериментально реализована ландшафтная мера сложности модели. Основной исследовательский вопрос состоит в том, как меняется данная мера при изменении вероятности dropout. Интуитивно dropout является регуляризатором, поэтому можно ожидать, что при увеличении вероятности dropout модель становится менее чувствительной к отдельным объектам выборки, а соответствующая ландшафтная мера имеет тенденцию к убыванию. При этом строго монотонная зависимость не гарантируется, поскольку значение меры зависит от найденного минимума, состава выборки, архитектуры модели и способа вычисления Гессиана.

2 Теоретическая основа

2.1 Постановка задачи обучения

Пусть задана выборка

$$D = \{(x_i, y_i)\}_{i=1}^{m},$$

где $x_i \in \mathcal{X}$ — объект, а $y_i \in \mathcal{Y}$ — ответ. Рассматривается параметрическое семейство моделей

$$f_\theta : \mathcal{X} \to \mathcal{Y}, \qquad \theta \in \mathbb{R}^n.$$

Для функции потерь $\ell(f_\theta(x), y)$ эмпирический риск имеет вид

$$L_D(\theta) = \frac{1}{m} \sum_{i=1}^{m} \ell(f_\theta(x_i), y_i).$$

Обучение модели можно рассматривать как задачу минимизации эмпирического риска:

$$\theta^* \in \arg\min_{\theta \in \mathbb{R}^n} L_D(\theta).$$

Локальные свойства функции L_D в окрестности точки θ^* описываются градиентом и матрицей Гессе.

2.2 Индивидуальные матрицы Гессе

Для каждого объекта выборки введем индивидуальную функцию потерь

$$L_i(\theta) = \ell(f_\theta(x_i), y_i).$$

Тогда индивидуальная матрица Гессе имеет вид

$$H_i(\theta) = \nabla_\theta^2 L_i(\theta) \in \mathbb{R}^{n \times n}.$$

Средний Гессиан по выборке равен

$$\overline{H}(\theta) = \frac{1}{m} \sum_{i=1}^{m} H_i(\theta).$$

В точке θ^* матрицы $H_i(\theta^*)$ описывают вклад отдельных объектов в локальную кривизну функции потерь. Если эти матрицы близки друг к другу, то различные объекты выборки задают похожую локальную геометрию. Если же они сильно отличаются, то оптимизационный ландшафт существенно зависит от конкретного объекта.

2.3 Ландшафтная мера сложности

Следуя подходу [1], ландшафтная мера сложности параметрической модели на выборке D определяется как

$$\mu_f(f|D) = \mathbb{E}_{x_i \in D} \left\| H_i(\theta^*) - \mathbb{E}_{x_i \in D} H_i(\theta^*) \right\|_2. \tag{1}$$

В конечной выборке это выражение записывается как

$$\widehat{\mu}_f(f|D) = \frac{1}{m} \sum_{i=1}^{m} \left\| H_i(\theta^*) - \overline{H}(\theta^*) \right\|_2, \tag{2}$$

где $\|\cdot\|_2$ — спектральная норма матрицы. Для симметричной матрицы A она равна

$$\|A\|_2 = \max_j |\lambda_j(A)|,$$

где $\lambda_j(A)$ — собственные значения матрицы A.

Содержательно величина (2) измеряет разброс индивидуальных кривизн относительно средней кривизны. Поэтому она может рассматриваться как характеристика того, насколько неоднородно отдельные объекты выборки влияют на локальную геометрию функции потерь.

2.4 Связь с анализом оптимизационного ландшафта

В теоретической основе данной работы важна следующая идея. При добавлении нового объекта в выборку изменение функции потерь в окрестности локального минимума может быть оценено через норму разности между индивидуальным Гессианом нового объекта и средним Гессианом по уже имеющейся выборке. В диссертационной работе эта идея приводит к оценке вида

$$|L_{k+1}(\theta) - L_k(\theta)| \le \frac{M_\ell}{k+1} + \frac{1}{k+1}\|\theta - \theta^*\|_2^2 \left\| H_{k+1}(\theta^*) - \frac{1}{k}\sum_{i=1}^{k} H_i(\theta^*) \right\|_2 .$$

Тем самым анализ изменения ландшафта сводится к анализу спектральной нормы разности Гессианов. Именно эта идея мотивирует экспериментальную оценку (2).

3 Экспериментальная постановка

3.1 Цель эксперимента

Целью эксперимента является исследование зависимости эмпирической ландшафтной меры сложности от вероятности dropout. Рассматривается семейство моделей $f_{\theta,p}$, где $p \in [0, 1)$ — вероятность dropout. Для каждого значения p модель обучается на одной и той же задаче классификации изображений, после чего в точке найденных параметров θ_p^* оценивается величина

$$\widehat{\mu}_f(f_{\theta_p}|D).$$

Основная гипотеза состоит в том, что увеличение dropout в среднем должно снижать чувствительность модели к отдельным объектам выборки. В терминах Гессианов это означает уменьшение разброса матриц $H_i(\theta_p^*)$ вокруг среднего Гессиана $\overline{H}(\theta_p^*)$. Однако данная зависимость не обязана быть строго монотонной из-за стохастического характера обучения и высокой чувствительности спектральной нормы.

3.2 Используемые данные и модели

В экспериментах использовался набор данных CIFAR-10. Для обучения применялась сверточная нейросетевая модель с двумя сверточными слоями, dropout и линейным классификационным слоем. Схематически модель имеет вид

$$\mathrm{Conv}_1 \to \mathrm{ReLU} \to \mathrm{Conv}_2 \to \mathrm{ReLU} \to \mathrm{Pooling} \to \mathrm{Dropout}(p) \to \mathrm{Linear}.$$

3.3 Dropout как исследуемый регуляризатор

Отдельно опишем слой dropout, поскольку именно его параметр варьируется в эксперименте. Пусть $z \in \mathbb{R}^d$ — вектор признаков, поступающий на dropout-слой, а $p \in [0, 1)$ — вероятность зануления отдельной координаты. Во время обучения генерируется случайная маска

$$\xi_j \sim \text{Bernoulli}(1-p), \qquad j = 1, \ldots, d,$$

и выход слоя в распространенной реализации inverted dropout имеет вид

$$\text{Dropout}_p(z)_j = \frac{\xi_j}{1-p} z_j.$$

Множитель $(1-p)^{-1}$ сохраняет математическое ожидание активации:

$$\mathbb{E}\,\text{Dropout}_p(z)_j = z_j.$$

На этапе применения модели dropout обычно отключается, и слой действует как тождественное отображение. Таким образом, во время обучения dropout случайно удаляет часть признаков и тем самым препятствует чрезмерной зависимости последующего слоя от отдельных координат представления. В данной работе dropout расположен непосредственно перед линейным классификатором, поэтому особенно естественно ожидать изменение ландшафтной меры именно в подпространстве параметров последнего слоя.

Для оценки ландшафтной меры были реализованы два подхода.

1) **Приближенный метод для последнего слоя.** Матрица Гессе явно не строится. Вместо этого используются произведения Гессиана на вектор. Оценка проводится только в подпространстве параметров последнего линейного слоя.

2) **Прямой метод для малой модели.** Для уменьшенной модели полная матрица Гессе строится явно по всем обучаемым параметрам. После этого напрямую вычисляются нормы $\|H_i - \overline{H}\|_2$.

Разделение на два метода связано с вычислительными ограничениями. Для полноценной модели число параметров достаточно велико, поэтому хранение полной матрицы Гессе становится практически невозможным. Для малой модели такой расчет возможен, но результат оказывается более чувствительным к шуму, поскольку учитываются все параметры, включая ранние сверточные слои.

4 Метод 1: приближенная оценка через Hessian-vector product

4.1 Идея метода

Пусть требуется оценить норму

$$\|H_i - \overline{H}\|_2.$$

Явно строить матрицы H_i и $\overline{H}$ дорого. Вместо этого можно использовать степенной метод, которому достаточно уметь вычислять произведение матрицы на вектор:

$$(H_i - \overline{H})v = H_i v - \overline{H} v.$$

Произведение $H_i v$ можно вычислить средствами автоматического дифференцирования без явного построения H_i. Действительно, если

$$g_i(\theta) = \nabla_\theta L_i(\theta),$$

то

$$H_i v = \nabla_\theta \langle g_i(\theta), v \rangle.$$

Такой подход называется Hessian-vector product.

4.2 Важная корректировка реализации

В первоначальной реализации средний член $\overline{H}v$ вычислялся один раз для фиксированного случайного вектора v_0. После этого в степенном методе вектор v изменялся, но вычитался все тот же вектор $\overline{H}v_0$. В результате фактически вычислялось

$$H_i v - \overline{H} v_0,$$

а не

$$H_i v - \overline{H} v.$$

Это нарушает математический смысл степенного метода, поскольку отображение

$$v \mapsto H_i v - \overline{H} v_0$$

не является линейным оператором. В исправленной реализации на каждой итерации степенного метода вычисляется именно

$$\overline{H} v = \frac{1}{m} \sum_{j=1}^{m} H_j v$$

для текущего вектора v.

Для ускорения расчета среднее $\overline{H}v$ оценивается по небольшой фиксированной подвыборке объектов. Таким образом, используется монте-карловская аппроксимация:

$$\overline{H} v \approx \frac{1}{s} \sum_{j \in S} H_j v,$$

где $S \subset D$, $|S| = s$.

4.3 Ограничение метода

В первом методе расчет проводится только по параметрам последнего линейного слоя. Поэтому экспериментально оценивается не полная мера (2), а ее частичная версия:

$$\widehat{\mu}_{\text{last}}(f|D) = \frac{1}{m} \sum_{i=1}^{m} \left\| H_i^{\text{last}}(\theta^*) - \overline{H}^{\text{last}}(\theta^*) \right\|_2.$$

Такое ограничение является осознанным вычислительным компромиссом. Оно позволяет работать с моделью большего размера, не сохраняя полную матрицу Гессе.

4.4 Результаты первого метода

На рис. 1 предполагается вставить график зависимости ландшафтной меры последнего слоя от вероятности dropout.

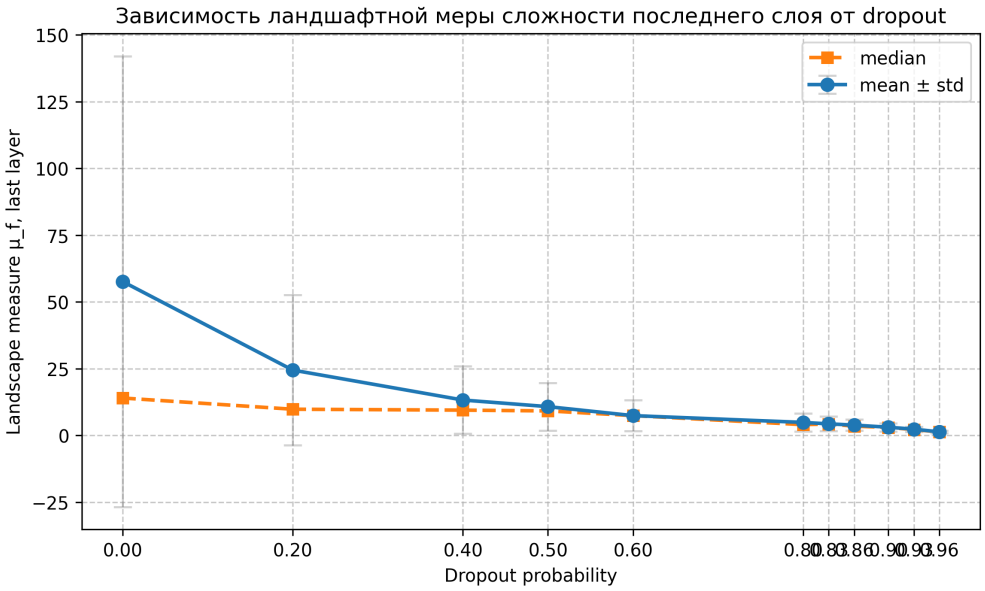


Рис. 1: Зависимость ландшафтной меры сложности последнего слоя от вероятности dropout. Здесь используется HVP-оценка и степенной метод.

Полученная зависимость имеет убывающий характер. Это согласуется с интуицией: dropout расположен непосредственно перед последним линейным слоем, поэтому увеличение вероятности dropout снижает устойчивую совместную активацию признаков, поступающих на классификатор, и уменьшает разброс локальных кривизн в подпространстве параметров последнего слоя.

5 Метод 2: прямое вычисление полной матрицы Гессе

5.1 Идея метода

Во втором методе используется малая сверточная модель, для которой возможно явно построить полную матрицу Гессе по всем обучаемым параметрам. Для каждого объекта x_i вычисляется

$$H_i = \nabla^2_\theta L_i(\theta^*).$$

Затем находится средний Гессиан

$$\overline{H} = \frac{1}{m}\sum_{i=1}^{m} H_i,$$

и для каждого объекта вычисляется

$$\|H_i - \overline{H}\|_2.$$

Итоговая оценка имеет вид

$$\widehat{\mu}_{\text{full}}(f|D) = \frac{1}{m}\sum_{i=1}^{m} \|H_i - \overline{H}\|_2.$$

Так как матрица Гессе является симметричной, в реализации после вычисления применяется симметризация

$$H \leftarrow \frac{1}{2}(H + H^\top),$$

а спектральная норма вычисляется как максимум модуля собственных значений:

$$\|H\|_2 = \max_j |\lambda_j(H)|.$$

5.2 Почему второй график может быть менее гладким

В отличие от первого метода, прямой метод оценивает кривизну по всем параметрам модели. Это делает его более близким к исходному определению (2), но одновременно повышает чувствительность оценки. Основные причины немонотонности и большой дисперсии следующие.

1) **Учет ранних сверточных слоев.** Параметры первых слоев влияют на все последующие признаки. Поэтому индивидуальные Гессианы по ранним слоям могут сильно отличаться для разных объектов.

2) **Малая модель хуже аппроксимирует CIFAR-10.** Если модель недостаточно выразительна, она может не приходить к устойчивому локальному минимуму. В таком случае Гессиан отражает не только сложность решения, но и нестабильность недообученной модели.

3) **Спектральная норма чувствительна к выбросам.** Один объект с большой кривизной может существенно увеличить значение меры.

4) **Dropout меняет найденный минимум.** Для разных значений p оптимизация приходит в разные точки θ_p^*. Следовательно, сравниваются не только разные регуляризации, но и разные области параметрического пространства.

5) **Случайность подвыборки.** При малом числе объектов оценка среднего Гессиана может иметь высокую дисперсию. Поэтому в реализации используются фиксированные подвыборки и усреднение по нескольким наборам объектов.

5.3 Результаты второго метода

На рис. 2 предполагается вставить график зависимости полной ландшафтной меры от вероятности dropout.

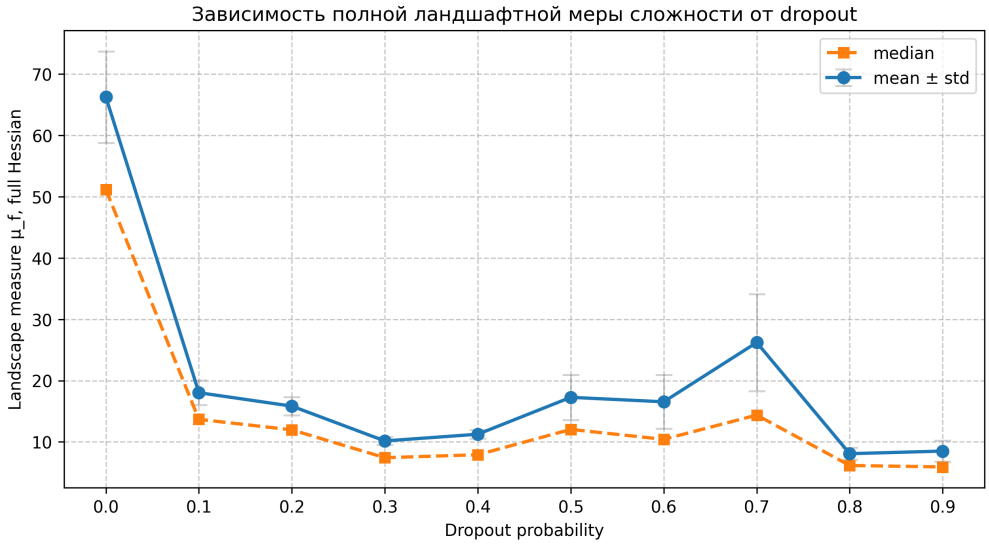


Рис. 2: Зависимость полной ландшафтной меры сложности от вероятности dropout для малой модели. Здесь матрица Гессе строится явно.

В отличие от первого метода, график второго метода может быть менее гладким. Это не является противоречием, поскольку два метода оценивают разные величины. Первый метод измеряет кривизну только в подпространстве последнего слоя, тогда как второй метод учитывает полную кривизну модели. Поэтому второй метод более чувствителен к архитектуре, качеству обучения и составу подвыборки.

6 Сравнение двух подходов

Сравним два метода с математической и вычислительной точек зрения.

Таблица 1: Сравнение методов оценки ландшафтной меры

Свойство	Метод 1: HVP	Метод 2: полный Гессиан
Область параметров	Последний слой	Все параметры малой модели
Матрица Гессе	Не строится явно	Строится явно
Основная операция	Hv	H_i и собственные значения
Вычислительная стоимость	Ниже	Выше
Близость к полной мере	Частичная оценка	Ближе к определению
Устойчивость графика	Выше	Ниже
Интерпретация	Кривизна классификатора	Полная кривизна модели

Таким образом, убывающий график первого метода показывает, что dropout уменьшает разброс кривизны последнего слоя. Второй метод проверяет более сильное утверждение: уменьшается ли разброс кривизны всей модели. Это утверждение является более сложным и не обязано выполняться столь же гладко.

7 Выводы

В течение семестра была изучена теория ландшафтной меры сложности параметрических моделей глубокого обучения и реализованы два экспериментальных способа ее оценки. Основные результаты можно сформулировать следующим образом.

1) Изучено определение ландшафтной меры сложности модели через спектральную норму отклонения индивидуальных матриц Гессе от среднего Гессиана.

2) Реализован приближенный метод оценки на основе Hessian-vector product и степенного метода без явного хранения полной матрицы Гессе.

3) Найдена и исправлена методическая ошибка в HVP-методе: средний член $\overline{H}v$ должен вычисляться для текущего вектора v на каждой итерации степенного метода.

4) Показано, что для последнего линейного слоя зависимость ландшафтной меры от dropout имеет убывающий характер.

5) Реализован прямой метод вычисления полной матрицы Гессе для малой модели.

6) Установлено, что прямой метод дает более шумную зависимость, поскольку учитывает все параметры модели и сильнее зависит от качества найденного минимума и состава подвыборки.

Главный вывод состоит в том, что dropout действительно может снижать эмпирическую ландшафтную меру сложности в подпространстве последнего слоя. При этом данный вывод относится к конкретной экспериментальной постановке: dropout расположен непосредственно перед линейным классификатором, а первый метод измеряет кривизну именно этого классификационного слоя. Прямой метод с полной матрицей Гессе показывает, что перенос такого вывода на всю модель является более сложной задачей, поскольку полная мера учитывает также ранние сверточные слои и поэтому имеет большую дисперсию.

Отдельно отметим, что малая модель во втором методе не является недостатком постановки, а является необходимым вычислительным ограничением: только для достаточно малой сети удается явно построить и сохранить полную матрицу Гессе. Более того, для дальнейшей проверки прямого метода имеет смысл рассмотреть еще меньшие архитектуры или синтетические задачи, на которых полный Гессиан можно вычислять для большего числа объектов и для более плотной сетки значений dropout. Такой эксперимент позволит отделить численную дисперсию оценки от собственно эффекта регуляризации.

8 Планы дальнейшей работы

Дальнейшая работа может развиваться в нескольких направлениях.

1) Уточнить зависимость от dropout на более плотной сетке значений. В текущем эксперименте уже рассматривается сетка

$$p \in \{0.0, 0.1, 0.2, \ldots, 0.9\}.$$

Следующий шаг состоит не просто в добавлении этих точек, а в локальном измельчении сетки на участках, где график меняется наиболее резко, например с шагом 0.05.

2) Для прямого метода рассмотреть еще меньшие модели или более простые данные. Это позволит вычислять полный Гессиан на большем числе объектов и уменьшить дисперсию оценки без перехода к HVP-аппроксимации.

3) Провести несколько запусков обучения для каждого значения dropout с разными random seed и усреднить результаты.

4) Исследовать влияние положения dropout-слоя. В данной работе dropout расположен перед последним линейным слоем, поэтому первый метод естественно анализирует именно этот слой. В дальнейшем можно поместить dropout в другую часть архитектуры или добавить несколько dropout-слоев и сравнить, как меняется ландшафтная мера соответствующих слоев.

5) Провести аналогичный послойный эксперимент для других подпространств параметров: первого сверточного слоя, второго сверточного слоя и последнего линейного слоя. Это позволит проверить, является ли убывание меры специфичным для слоя, непосредственно следующего за dropout, или наблюдается также в более ранних слоях.

6) Сравнить ландшафтную меру с качеством модели на валидационной выборке, чтобы понять связь между сложностью и обобщающей способностью.

7) Исследовать влияние других регуляризаторов, например weight decay и batch normalization.

8) Реализовать более точные стохастические оценки полной ландшафтной меры без явного построения полного Гессиана.

Список литературы

[1] Грабовой А. В. *О сложности моделей и данных в параметрических моделях глубокого обучения*. Диссертация на соискание ученой степени доктора физико-математических наук. Москва, 2025.

[2] Goodfellow I., Bengio Y., Courville A. *Deep Learning*. MIT Press, 2016.

[3] Bishop C. M. *Pattern Recognition and Machine Learning*. Springer, 2006.

[4] LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 1998.